

Qurity report e_commerce_raw.csv

จากข้อมูล

Metric		Before	After
0	Total rows	630	612
1	Exact duplicate rows	18	0
2	Missing Customer_Email	48	0
3	Missing Province	12	0
4	Gender format variants	10	2
5	Payment_Method format variants	14	5
6	Order_Date unparseable/invalid	0	0
7	Quantity outside business rule (1-20)	3	3
8	Accuracy mismatch (non-promo, >1 baht)	43	43
9	Order_Status non-standard rows	320	308
10	Outliers outside IQR bound (non-promo)	19	0
11	Late loads (Load_Delay_Hours > 24h)	48	48

บทสรุปภาพรวม (Executive Summary)

การทำ Data Cleaning ครั้งนี้มีวัตถุประสงค์เพื่อยกระดับคุณภาพข้อมูล (Data Quality) และเตรียมข้อมูลให้พร้อมสำหรับการนำเข้าสู่ Data Warehouse โดยยึดหลัก

รักษาตัวเลขยอดขาย (Revenue Preservation), จัดรูปแบบมาตรฐาน (Standardization) และ

สร้างระบบย้อนตรวจสอบได้ (Auditability)

จำนวนแถวรวม: ลดลงจาก 630 เหลือ 612 แถว (ลบแถวซ้ำสมบูรณ์ 18 แถว)

Missing Values: จัดการครบ 100% (Email 48 รายการ, Province 12 รายการ) โดยไม่เสีย Fact Table

Standardization: ปรับรูปแบบ Gender (เหลือ M, F) และ Payment Method (เหลือ 5 ช่องทางหลัก) ให้เป็นมาตรฐาน

Outliers: ทำ Capping รายการที่ไม่ใช่โปรโมชั่น 19 รายการ ด้วยวิธี IQR

ด้านความครบถ้วน (Completeness)

Customer_Email (48 รายการ): เติมด้วย unknown_customer@placeholder.com พร้อมติด Flag ไม่ใช่ dropna() เพราะจะทำให้ยอดขายรวมใน Fact Table สูญหาย

Province (12 รายการ): เติมด้วย 'Unknown' พร้อมติด Flag เพื่อย้อนมาอัปเดตข้อมูลที่หลังได้

ด้านความสอดคล้อง (Consistency)

Gender: Map คำสะกดต่างๆ ให้เหลือ M, F และ Unknown

Payment_Method: Map รูปแบบคำสะกด (เช่น CC, CreditCard) ให้เหลือ 5 กลุ่มมาตรฐาน (Credit Card, PromptPay, Cash on Delivery, Bank Transfer, Unknown) Order_Date & Order_Status: แปลงวันที่เป็น YYYY-MM-DD โดยใช้ Load_Timestamp ช่วยตัดสินความถูกต้อง และจัดรูปแบบสถานะคำสั่งซื้อเป็น Title Case

ด้านความซ้ำซ้อน (Uniqueness)

Exact Duplicates (18 รายการ): ลบแถวที่ซ้ำกันทุกคอลัมน์โดยเก็บเฉพาะแถวแรกไว้ (keep='first')

ด้านกฎธุรกิจและความถูกต้อง (Accuracy & Validity): Quantity & Accuracy Mismatch: แถวที่จำนวนสินค้าอยู่นอกช่วง 1–20 ชิ้น หรือยอดเงินไม่ตรงกับสูตรคำนวณ จะถูกติด Quality Flag ไว้เพื่อไม่ให้กระทบโครงสร้างข้อมูล แต่ใช้ส่งต่อให้ทีมที่เกี่ยวข้องตรวจสอบ

ด้านค่าผิดปกติ (Outliers & IQR)

Outliers (19 รายการ): คำนวณ IQR เฉพาะกลุ่ม Is_Promotion != 'Y' แล้วทำ Capping ขอบบน/ลบด้วย .clip() โดยไม่ลบรายการโปรโมชั่นทิ้งเพราะเป็นยอดขายจริงจากแคมเปญ

ด้านความทันเวลา (Timeliness)

Late Loads (48 รายการ): คำนวณระยะเวลาโหลดข้อมูล หากเกิน 24 ชั่วโมงจะติด Is_Late_Load = True เพื่อประเมินประสิทธิภาพ Data Pipeline